FIAP · PÓS-GRADUAÇÃO IA PARA DEVS · TURMA 9IADT

VitalTrace

Monitoramento multimodal de pacientes com detecção de anomalias e alertas à equipe médica

> **Relatório Técnico — Tech Challenge · Fase 4**
>
> Integrantes: Bruno Gouveia Schoola · Ricardo Stebulaitis
>
> Repositório: `github.com/bschoola/AI-fiap-techchallenge-fase4`
>
> Novembro de 2026

Todos os dados do projeto são fictícios e sintéticos. As regras e limiares são heurísticas didáticas, sem validação clínica: o sistema apoia, não substitui, a decisão médica.

1. Introdução e objetivo

Equipes médicas acompanham dezenas de pacientes entre consultas e perdem sinais precoces de piora porque eles aparecem em fontes diferentes: na voz do paciente durante a gravação da consulta, no movimento em um vídeo de fisioterapia, nas séries de sinais vitais, na evolução das prescrições e no texto da anamnese. O **VitalTrace** é um portal médico que ingere essas fontes, detecta anomalias em cada uma, cruza as modalidades e avisa a equipe **dentro da própria aplicação**, com o motivo e a evidência de cada alerta.

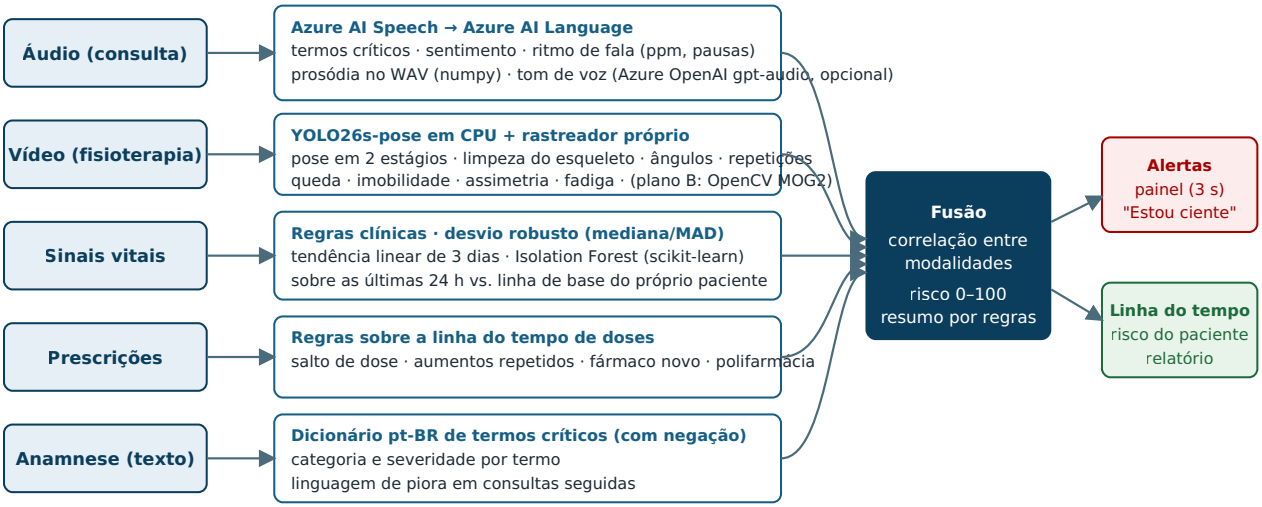
O projeto responde aos requisitos do Tech Challenge Fase 4: processamento multimodal (áudio, vídeo e dados clínicos estruturados), detecção de anomalias, integração com serviços em nuvem (Azure AI Speech, Azure AI Language e, opcionalmente, Azure OpenAI) e geração de alertas para a equipe médica. A restrição de projeto foi rodar tudo em **CPU**, sem GPU, com dados 100 % sintéticos.

1.1 O que o portal faz

Tela	Função
Login	Acesso do médico (senha com *scrypt*, sessão em cookie assinado).
Pacientes	5 atendimentos mais recentes, "Ver todos os 30 pacientes" e busca por nome sem acento/maiúscula.
Alertas	Painel atualizado a cada 3 s (HTMX), faixa vermelha para críticos e botão **Estou ciente**, que registra quem confirmou e quando.
Paciente → Analisar gravação	Upload de áudio (ou transcrição colada): Azure Speech → Azure Language → termos críticos, sentimento, ritmo de fala e prosódia → alertas.
Paciente → Análise de vídeo	Upload de vídeo ou link do YouTube: rastreia as pessoas, fixa o paciente (o médico escolhe quando há mais de uma), estima a pose em CPU → descrição do que foi visto, ângulos por articulação, repetições, queda, imobilidade, assimetrias → relatório e vídeo com o esqueleto desenhado.
Paciente → Evolução clínica	Linha do tempo (consultas, áudios, vídeos e análises de IA), gráficos de SpO_2/FC com mudanças de dose e marcadores de áudio/vídeo, prescrições e botão **Análise de anomalias com IA**.

2. Descrição do fluxo multimodal

Cada modalidade tem um pipeline próprio que transforma o dado bruto em uma lista de **achados** (`Finding`: origem, detector, severidade, título, descrição e evidência). Os achados de todas as modalidades convergem para um módulo de **fusão**, que correlaciona as fontes, calcula um risco de 0 a 100 por paciente e converte os achados de severidade alta ou crítica em alertas no painel da equipe.



Cada caixa devolve achados (Finding) com origem, severidade, descrição e evidência; só alto/crítico viram alertas.

2.1 Fluxo de um achado, passo a passo

1. **Entrada.** O médico envia um áudio ou vídeo pela tela do paciente, cola um link do YouTube, ou clica em *Análise de anomalias com IA* na evolução clínica (que lê sinais vitais, prescrições, anamneses e o histórico de vídeos do banco).
2. **Pipeline da modalidade.** O módulo correspondente (`audio/`, `video/`, `anomaly/`) processa o dado e devolve achados. O áudio, por exemplo, passa por transcrição (Azure Speech), análise do texto (Azure Language), dicionário de termos críticos, métricas de ritmo e prosódia calculada direto no sinal.
3. **Fusão.** `fusion/risk.py` soma pontos por severidade (teto de 50 por modalidade, para que o score exija convergência de fontes), gera achados de correlação (por exemplo, *piora clínica apesar do ajuste de dose*) e define o nível: *estável*, *atenção* ou *crítico* (este só com algum achado crítico).
4. **Alertas.** Achados de severidade alta ou crítica viram alertas no banco (sem duplicar os que já estão em aberto para o mesmo paciente, origem e título). O painel consulta a cada 3 s; críticos acendem uma faixa vermelha; **Estou ciente** encerra o alerta registrando quem e quando.
5. **Registro.** Cada análise é salva na linha do tempo com o que foi analisado (transcrição com termos destacados; quadros-chave do vídeo) e o resultado. Por privacidade, o áudio e o vídeo originais não são guardados: só a transcrição, até 3 quadros reduzidos e, opcionalmente, um vídeo reduzido com o esqueleto.

2.2 Arquitetura e decisões

- **Portal sem build de front-end**: FastAPI + Jinja2 + HTMX; gráficos SVG gerados no servidor. Banco em SQLAlchemy 2 (Postgres no Docker; SQLite local e nos testes), seed idempotente com 1 médico e 30 pacientes.
- **Serviços atrás de interfaces** (`Transcriber`, `TextAnalyzer`, `PersonEstimator`): trocar Azure por simulado (`MOCK_AZURE=true`) ou YOLO por OpenCV não toca o resto do código.
- **Explicabilidade**: apenas quatro pontos usam aprendizado de máquina (YOLO-pose, Isolation Forest e os serviços Azure); o restante é regra ou estatística, para que cada alerta seja auditável.
- **Alertas na própria aplicação**, sem e-mail ou webhook, conforme decisão de projeto.

- **Estrutura**: `src/vitaltrace/{web, audio, video, anomaly, fusion, alerts, db}`, `scripts/` (smoke test do Azure, geração de áudios, avaliação) e `tests/` (207 testes).

3. Modelos aplicados em cada tipo de dado

Nenhum modelo foi treinado com dados reais de pacientes: o YOLO usa pesos pré-treinados da Ultralytics, o Isolation Forest é ajustado na hora com a série de cada paciente, e os serviços Azure são gerenciados. Todos os limiares são pontos de partida configuráveis em `config.py`.

3.1 Áudio

Etapa	Modelo / técnica	Por quê e saída
Transcrição	**Azure AI Speech**, reconhecimento contínuo pt-BR com marcação por palavra (`request_word_level_timestamps`). Com `MOCK_AZURE=true`, transcritor simulado.	Serviço gerenciado para áudios longos; devolve texto e segmentos com tempo.
Sentimento e frases-chave	**Azure AI Language** (`analyze_sentiment`, `extract_key_phrases`), texto dividido em blocos de até 4000 caracteres e lotes de 10 documentos.	Sentimento por trecho e frases-chave para o resumo.
Termos críticos	**Regras**: dicionário pt-BR com categoria e severidade (respiratório, cardiovascular, neurológico, dor, geral), sem acento, ignorando termos negados ("sem falta de ar").	Detecta "falta de ar", "dor no peito", "tontura"… e gera alerta por termo.
Ritmo de fala	**Métricas** a partir dos tempos da transcrição: palavras/min, proporção de pausa e velocidade "sem as pausas".	Indício de fadiga ou disartria; só alerta em trechos longos o bastante.
Prosódia (como a pessoa fala)	**Processamento de sinal** com numpy no WAV (`audio/prosody.py`): energia por quadro, trechos de fala e silêncio, número e duração das pausas, duração média de cada frase, F0 por autocorrelação e sua variação em semitons.	Mede o *como*, independente das palavras e do Azure; roda em CPU e é explicável.
Tom de voz (opcional)	**Azure OpenAI** `gpt-audio` ouvindo a gravação (`VOICE_TONE_ENABLED=true`): esforço respiratório, cansaço e tom emocional em JSON.	Segunda opinião; sozinho gera no máximo alerta médio, porque a resposta varia.

Fusão do áudio	**Regra**: silêncio ≥ 45 % + mediana de pausa ≥ 0,8 s + ≥ 6 pausas longas/min + frases ≤ 2 s ⇒ *Fala entrecortada* (alta); vira *crítica* se confirmada por queixa transcrita ou pelo tom de voz.	Percebe esforço respiratório mesmo quando o paciente não diz "falta de ar".

3.2 Vídeo

Etapa	Modelo / técnica	Por quê e saída
Pessoas e pose	**YOLO26s-pose** (`ultralytics`, CPU): quadro reduzido a 960 px, entrada de 640 px; caixa e 17 pontos de todas as pessoas. Fallback para `yolo11s-pose` e `yolov8n-pose`.	Modelo leve o suficiente para CPU; 8 quadros/s no modo detalhado, 2 no rápido.
Quem é o paciente	**Rastreador próprio** (`video/tracking.py`): associação entre quadros por sobreposição de caixa e distância do esqueleto (algoritmo húngaro); reencontro após corte pela cor da roupa.	Evita misturar paciente e terapeuta. O médico escolhe a pessoa quando há mais de uma candidata; senão, a que fica mais tempo, maior e se move mais.
Pose em dois estágios	Segunda passada só no **recorte do paciente em resolução original** (entrada 480 px) quando isso dá mais pixels que o quadro inteiro.	Melhora as articulações de quem aparece pequeno.
Limpeza e suavização	`video/clean.py`: desfaz trocas esquerda/direita, descarta pontos que "esticam" um osso, confiança mínima 0,5 nos ângulos; mediana móvel de 3 quadros.	Reduz ruído da pose 2D antes das medidas.
Eventos básicos	**Regras geométricas**: queda = de pé para deitado em ≤ 2 s e permanência ≥ 3 s; imobilidade = movimento < 0,03 altura-do-corpo/s; ângulo e assimetria de joelhos; índice de mobilidade (mediana do movimento normalizada).	Queda (crítico), imobilidade prolongada (médio), baixa mobilidade.
Análise detalhada	Cortes de cena (histograma + miniatura), vista da câmera (frontal/oblíqua/lateral), tronco inclinado, ombros/quadril desalinhados, oscilação postural, assimetria de amplitude entre lados, ritmo irregular (CV > 35 %) e fadiga (amplitude do último terço ≥ 25 % menor).	Descrição trecho a trecho, tabela de ângulos (joelho, quadril, ombro, cotovelo), relatório de qualidade e vídeo anotado.
Narrativa (opcional)	6 quadros para um modelo multimodal do **Azure OpenAI** (`VIDEO_NARRATIVE_ENABLED`).	Descreve ambiente e cena; não entra em medidas nem alertas.

Plano B	**OpenCV**: subtração de fundo MOG2 e maior região em movimento (caixa, sem articulações).	Ativo quando o YOLO não está instalado; usado nos testes automatizados.

3.3 Sinais vitais, prescrições e anamnese

Dado	Modelo / técnica	Por quê e saída
Sinais vitais	Quatro camadas: (1) **regras clínicas** (ex.: SpO_2 < 90 % crítico, < 92 % alto); (2) **desvio robusto** da média das últimas 24 h contra mediana/ MAD da linha de base do próprio paciente; (3) **tendência** por regressão linear em 3 dias (com R^2); (4) **Isolation Forest** do scikit-learn (100 árvores, `StandardScaler`) treinado na linha de base e aplicado às últimas 24 h, só quando algum sinal já saiu do habitual.	Camadas explicáveis; o Isolation Forest cobre combinações multivariadas incomuns que nenhuma regra isolada pega. É o único modelo de ML treinado no projeto.
Prescrições	**Regras** sobre a linha do tempo de doses: salto (razão ≥ 2×), aumentos repetidos em 60 dias, fármaco novo, polifarmácia.	Mudanças rápidas de dose sugerem resposta clínica insuficiente.
Movimento (histórico)	**Regras** sobre as últimas análises de vídeo: queda ≥ 25 % no índice de mobilidade e quedas no vídeo mais recente.	Conecta a evolução motora ao risco do paciente.
Anamnese	**Regras**: o mesmo dicionário de termos críticos do áudio e linguagem de piora em consultas seguidas.	Reaproveita o detector e cruza com os sinais medidos.
Fusão e resumo	**Pontuação por regra** (pontos por severidade, teto por modalidade, correlações) e **resumo textual determinístico**, sem LLM, sempre com aviso de que não é diagnóstico.	Risco 0–100, nível e texto reproduzível.

4. Dados utilizados

- **Pacientes e séries clínicas**: 30 pacientes fictícios gerados por um seed determinístico (`db/seed.py`): 14 dias de sinais vitais com 6 aferições/dia, 3–5 consultas com anamnese, prescrições e histórico de vídeo. Três pacientes têm roteiro clínico (deriva crítica, deriva de atenção e DPOC) e os demais são estáveis.
- **Áudio**: seis gravações sintéticas em pt-BR geradas com Azure (`scripts/generate_sample_audio.py` e `generate_consulta_audio.py`), em tomada única para que respiração, hesitação e ritmo saiam do próprio modelo de voz: *consulta normal*, *consulta com falta de ar* (fala lenta e entrecortada, sem dizer "falta de ar"), *consulta com dor no peito*, e três curtas (*crítico*, *estável*, *fadiga*).

- **Vídeo**: nos testes automatizados, vídeos sintéticos gerados na hora (uma "pessoa" retangular que anda, cai ou fica parada) e esqueletos sintéticos (duas pessoas, oclusão, troca de lado, vista lateral). Para a demonstração, gravações próprias ou clipes públicos de câmera parada.
- **PhysioNet / AudioSet**: citados no enunciado como sugestão, **não foram usados** nesta versão. A estrutura aceita séries reais (basta gravar linhas em `vital_signs`); preferimos declarar isso a apresentar dados sintéticos como reais.

5. Resultados obtidos

5.1 Testes automatizados

207 testes (`pytest`) passam sem Azure e sem YOLO, cobrindo termos críticos e negação, métricas de ritmo, prosódia, tom de voz, motor de alertas, detectores de sinais vitais, prescrições e anamnese, rastreamento e limpeza de esqueleto, análise detalhada de vídeo, link do YouTube, seed, segurança, linha do tempo e rotas do portal. Tempo total: cerca de 30 s em CPU.

5.2 Detecção em séries de sinais vitais

Avaliação com `scripts/evaluate_anomalies.py 150`: 150 séries sintéticas por perfil, nível calculado só com os detectores de sinais vitais. Os rótulos vêm do gerador, portanto isto é uma checagem dos limiares, não uma validação clínica.

Perfil gerado	Estável	Atenção	Crítico
Estável	100,0 %	0,0 %	0,0 %
Deriva leve (SpO_2 −3, FC +9 em 5 dias)	44,0 %	55,3 %	0,7 %
Deriva grave (SpO_2 −7,5, FC +28 em 4 dias)	0,0 %	49,3 %	50,7 %

Leitura: falso alarme de 0 % nas séries estáveis (limiares conservadores); sensibilidade de 56 % para a deriva leve (≥ atenção) e de 50,7 % para a deriva grave chegar a *crítico*. Nenhuma deriva grave fica como "estável": as que não chegam a crítico param em atenção, porque o nível crítico exige cruzar um limiar clínico duro (ex.: SpO_2 < 90 %). Limiares mais sensíveis aumentariam a detecção ao custo de falsos alarmes; a escolha foi privilegiar a confiança do médico no painel.

5.3 Análise dos 30 pacientes do seed

Rodando *Análise de anomalias com IA* para toda a base: **1 paciente crítico** (Helena Martins Duarte, 100/100), **9 em atenção** (de 17 a 89 pontos) e **20 estáveis** (0–5 pontos). A distribuição coincide com os perfis plantados no seed, e os pacientes estáveis não geram alertas.

Paciente	Motivo do acompanhamento	Nível	Risco	Achados
Helena Martins Duarte (67)	Dispneia e dor torácica	**crítico**	100	22
Roberto Almeida Lima (72)	Insuficiência cardíaca	**atenção**	89	6

Paulo Roberto Araújo (69)	DPOC	**atenção**	37	2
Alexandre Pinto Rezende	Arritmia	**atenção**	36	3
Antônio Carlos Medeiros	Pós-AVC, fonoterapia	**atenção**	29	3
Carlos Eduardo Pereira	Cefaleia recorrente	estável	0	0
Outros 19 pacientes	—	estável	0–5	0–1

5.4 Áudio: prosódia nas seis gravações de exemplo

Métricas calculadas diretamente no sinal (`audio/prosody.py`), sem depender da transcrição. As duas gravações feitas para simular esforço respiratório são as únicas que cruzam os quatro limiares de "fala entrecortada" (silêncio ≥ 45 %, mediana de pausa ≥ 0,8 s, ≥ 6 pausas longas/min, frases ≤ 2 s); as demais ficam claramente abaixo.

Gravação	Duração	Silêncio	Pausas longas/min	Mediana da pausa	Frase média	F0 mediana	Fala entrecortada
consulta_normal	59,2 s	28,5 %	0,0	0,49 s	1,27 s	232 Hz	não
consulta_dor_no_peito	40,9 s	34,3 %	0,0	0,58 s	1,01 s	222 Hz	não
consulta_falta_de_ar	83,4 s	**54,2 %**	**17,4**	**1,06 s**	**0,88 s**	211 Hz	**sim**
paciente_estavel	7,0 s	4,4 %	0,0	0,27 s	2,92 s	250 Hz	não
paciente_critico	7,9 s	5,0 %	0,0	0,35 s	3,33 s	260 Hz	não
paciente_fadiga	18,8 s	**50,8 %**	**17,2**	**1,81 s**	**1,43 s**	242 Hz	**sim**

Isso confirma o objetivo de perceber *como* o paciente fala: a gravação "falta de ar" nunca pronuncia essa expressão e, ainda assim, é sinalizada pelo ritmo e pelas pausas. Com as chaves do Azure configuradas, a transcrição e o sentimento complementam esse resultado com os termos críticos ditos (ex.: "dor no peito", "braço esquerdo", "suor frio" na terceira gravação) e o alerta de fala entrecortada sobe de *alto* para *crítico* quando há queixa transcrita que o confirme.

5.5 Vídeo: eventos em vídeos sintéticos (motor OpenCV, 2 quadros/s)

Cenário	Resultado
3 s vazio + 8 s andando + 10 s deitado	**Queda suspeita (11–21 s)**: "passou da posição vertical para deitado em menos de 2 s e permaneceu assim por cerca de 10 s" → alerta crítico.
3 s vazio + 14 s andando	Nenhum evento; nenhum alerta.
3 s vazio + 3 s andando + 30 s parado	**Imobilidade prolongada** ("quase sem movimento por 18 s seguidos") → alerta médio; índice de mobilidade baixo (0,00) → achado de baixa severidade.
Agachar por 1,5 s	Não gera queda (janela de permanência de 3 s evita o falso positivo).

Com o **YOLO26s-pose** em pesos reais, o rastreamento multi-pessoa, a escolha do paciente, a limpeza do esqueleto e a descrição da cena foram validados com esqueletos sintéticos nos testes e, manualmente, em vídeos públicos de fisioterapia durante o desenvolvimento, onde a primeira versão errava o mapeamento das articulações e se perdia com mais de uma pessoa em cena. Esses dois problemas motivaram o rastreador próprio, a escolha do paciente pelo médico e a pose em dois estágios. Tempo de processamento em CPU: um vídeo de 2 minutos no modo detalhado (8 quadros/s + refinamento) leva alguns minutos; `yolo26n-pose`, `VIDEO_DETAIL_FPS=5` ou `VIDEO_REFINE_POSE=false` aceleram.

6. Exemplos de anomalias detectadas

6.1 Caso crítico — Helena Martins Duarte (67 anos, dispneia e dor torácica)

Resultado da fusão: **risco crítico, 100/100**, 22 achados (7 de severidade alta ou crítica), 4 alertas críticos em aberto. Resumo gerado pelo sistema: "*Helena Martins Duarte: risco crítico (100/100), com 22 achado(s), dos quais 7 de severidade alta ou crítica. Sinais vitais: SpO_2 em 89 %: saturação abaixo de 90 %; Frequência cardíaca acima da linha de base do paciente. Prescrição: Furosemida: dose de 40 mg para 80 mg (2,0×)… Correlação: Piora clínica apesar do ajuste de tratamento; Sintomas relatados coincidem com alterações medidas.*"

Severidade	Origem / detector	Achado e evidência
crítico	sinais vitais / regra	SpO_2 em 89 %: 4 aferições nas últimas 48 h abaixo de 90 %; pior valor 88 %.
crítico	anamnese / termos	Anamnese menciona "falta de ar" (respiratório) na última consulta.
crítico	áudio / termos	Termos críticos "falta de ar" (respiratório) e "dor no peito" (cardiovascular) na gravação da consulta.
alto	prescrição / dose	Furosemida de 40 mg para 80 mg (2,0×): 2 aumentos em 60 dias, o último hoje.
alto	fusão / correlação	**Piora clínica apesar do ajuste de tratamento**: aumento recente de dose e, ao mesmo tempo, SpO_2 e FC em deterioração. Sugere reavaliação presencial.
alto	fusão / correlação	**Sintomas relatados coincidem com alterações medidas**: a queixa (voz/anamnese) é compatível com os desvios objetivos.
médio	sinais vitais / z-score	FC 100 bpm vs. mediana habitual 77 (z robusto +5,2); SpO_2 89 % vs. 95 % (−3,9); FR 21 vs. 15 irpm (+3,8); temperatura 37,2 vs. 36,5 °C (+4,7).
médio	sinais vitais / tendência	SpO_2 −6,1 pontos em 3 dias (R^2 = 0,94); FC +25,6 bpm (R^2 = 0,86); FR +6,4 irpm (R^2 = 0,88); PAS +16,4 mmHg (R^2 = 0,71).
médio	sinais vitais / Isolation Forest	Combinação incomum de sinais: 7 de 7 aferições das últimas 24 h destoam do padrão multivariado da paciente.

médio	movimento / histórico	Queda de 38 % no índice de mobilidade (0,31 vs. média anterior 0,50 em 2 sessões).
médio	anamnese	"tontura" (neurológico); 2 das últimas 3 anamneses descrevem piora progressiva.
baixo	prescrição / anamnese	Espironolactona iniciada hoje (25 mg); termos "dor" e "cansaço".

6.2 Caso de atenção — Roberto Almeida Lima (72 anos, insuficiência cardíaca)

Risco atenção, 89/100, 6 achados. SpO_2 em 91 % (abaixo de 92 %, alto, mas acima do limiar crítico), queda progressiva de 3,3 pontos em 3 dias (R^2 = 0,81), furosemida dobrada hoje, Isolation Forest com 7/7 aferições fora do padrão e "tosse" na anamnese. A correlação *piora clínica apesar do ajuste de tratamento* é gerada, mas o paciente **não** chega a crítico porque nenhum limiar clínico duro foi cruzado. Este é o caso que mostra a diferença entre os níveis.

6.3 Caso de atenção leve — Paulo Roberto Araújo (69 anos, DPOC)

Risco atenção, 37/100, 2 achados: SpO_2 em 91 % em 2 aferições e 6 de 7 aferições destoando no Isolation Forest. Sem alteração de prescrição nem queixa na anamnese, o score fica baixo: a fusão exige convergência de fontes para subir.

6.4 Contraste — pacientes estáveis

Carlos Eduardo Pereira (cefaleia recorrente), Henrique Salgado Neto (apneia do sono) e outros 18 pacientes ficam com **0 achados, risco estável 0/100** e nenhum alerta. Resumo do sistema: "*nenhum desvio relevante nos sinais vitais, prescrições, movimento ou anamnese.*"

6.5 Anomalias de áudio e vídeo

- **Fala entrecortada** na gravação *consulta_falta_de_ar*: "54 % do tempo em silêncio, 24 pausas de 1 s ou mais (mediana de 1,1 s) e trechos de fala de 0,9 s em média: a pessoa interrompe a fala a cada poucas palavras" — detectada sem a expressão "falta de ar" aparecer no texto.
- **Termos críticos** na gravação *consulta_dor_no_peito* (com Azure): "dor no peito" (cardiovascular, crítico), sentimento predominantemente negativo.
- **Queda suspeita** em vídeo: transição de pé → deitado em menos de 2 s com permanência de ~10 s → alerta crítico com o intervalo (11–21 s) e quadro-chave na linha do tempo.
- **Imobilidade prolongada**: 18 s sem movimento → alerta médio.
- **Análise detalhada** (YOLO-pose): tronco inclinado > 20° por ≥ 5 s, ombros/quadril desalinhados > 8°, assimetria de amplitude entre lados < 65 %, ritmo irregular e fadiga em exercícios repetitivos; achados médios ou altos viram alerta, os baixos ficam no relatório com a curva de ângulo da articulação mais ativa.

7. Integração com serviços em nuvem (Azure)

- **Azure AI Speech** — Speech to Text pt-BR, reconhecimento contínuo com marcação por palavra. Usado na transcrição e no ritmo de fala.

- **Azure AI Language** — sentimento e frases-chave, com divisão em blocos de 4000 caracteres e lotes de 10 documentos.
- **Azure OpenAI** (opcional) — `gpt-audio` para tom de voz, modelo multimodal para a narrativa do vídeo e geração dos áudios sintéticos de exemplo.

Chaves e endpoints vêm do `.env` (nunca versionado); o passo a passo de criação de cada recurso está em `docs/azure-setup.md` e `scripts/azure_smoke_test.py` valida a configuração. Com `MOCK_AZURE=true` o portal roda inteiro sem nuvem, com serviços simulados, o que permite executar a suíte de testes e a demonstração offline.

8. Alertas à equipe médica

- Severidades: crítico, alto, médio, baixo. Só **alto e crítico** viram alertas; os demais ficam no relatório de anomalias e na linha do tempo.
- Entrega **dentro do portal**: o alerta fica no banco, o painel consulta a cada 3 s, uma faixa vermelha avisa sobre críticos e o botão **Estou ciente** registra quem confirmou e quando.
- Alertas duplicados (mesmo paciente, origem e título, ainda em aberto) não são recriados; cada alerta leva ao registro da linha do tempo que o originou, com a evidência.

9. Limitações, ética e LGPD

- Heurísticas e limiares didáticos, sem validação clínica; o resumo é gerado por regras e sempre avisa que não é diagnóstico.
- Pose 2D de uma câmera só, sem calibração: inclinação de câmera e visão lateral afetam ombros e quadril; em exercícios, inclinar o tronco pode ser o movimento esperado. O plano B (OpenCV) não vê articulações.
- O dicionário de termos é pequeno e ilustrativo; a prosódia é sensível a ruído de fundo e à qualidade do microfone.
- Dados fictícios. Com dados reais seriam necessários consentimento, minimização, criptografia, trilha de auditoria e controle de acesso por papel (hoje há apenas login de médico). Áudio e vídeo originais não são guardados.
- Vídeo por link do YouTube é só para demonstração com vídeos públicos; os Termos de Serviço restringem o download.
- Testes usam SQLite e serviços simulados; não há testes automáticos contra o Postgres do Docker nem contra o Azure.

10. Conclusão

O VitalTrace cobre as modalidades pedidas no desafio — áudio, vídeo e dados clínicos — com modelos adequados a CPU, serviços gerenciados do Azure onde fazem diferença (voz e texto) e uma camada de fusão explicável que transforma achados em alertas acionáveis dentro do portal. Os resultados mostram zero falso alarme em séries estáveis, detecção correta do esforço respiratório pela prosódia mesmo sem a queixa verbal, queda e imobilidade identificadas em vídeo e um caso crítico completo em que cinco fontes convergem para o mesmo diagnóstico de piora.

Como reproduzir

Docker: `copy .env.example .env` (preencha o Azure ou use `MOCK_AZURE=true`) → `docker compose up --build` → `http://localhost:8000`. Acesso de demonstração: `rafael.menezes@hospitalmodelo.demo` / `vitaltrace123`.

Local: Python 3.11+, `pip install -r requirements-dev.txt`, opcionalmente `torch` CPU + `requirements-video.txt` para o YOLO, `uvicorn vitaltrace.web.app:create_app --factory --app-dir src`.

Testes e avaliação: `pytest` · `python scripts/evaluate_anomalies.py 150` · `python scripts/azure_smoke_test.py`.